

Identificação de Perfis de Risco em Apostadores Online por Meio de Aprendizado de Máquina

Livia Negrucci Cantowitz

Faculdade de Computação e Informática – Universidade Presbiteriana Mackenzie
(UPM)

Rua da Consolação, 896 – 01302-907 – São Paulo – SP – Brasil

10389419@mackenzista.com.br

Abstract. *The growth of online betting among Brazilian university students has brought a rise in problematic use, often hard to identify in time. This work classifies bettors into risk profiles (low, medium, high) using supervised machine learning on a public Kaggle dataset with 100,000 bets from 5,000 users. Per-user feature engineering and an initial classification rule revealed clear differences across profiles: high-risk bettors bet more frequently, with higher amounts and longer losing streaks. Next step: compare classification algorithms and build an interactive prototype.*

Resumo. *O crescimento das apostas online entre universitários brasileiros trouxe consigo um aumento de casos de uso problemático, difíceis de identificar a tempo. Este trabalho classifica apostadores em perfis de risco (baixo, médio, alto) via aprendizado de máquina supervisionado, usando um dataset público do Kaggle com 100.000 apostas de 5.000 usuários. A engenharia de atributos por apostador e uma regra inicial de classificação revelaram diferenças claras entre perfis: apostadores de alto risco apostam mais vezes, com valores maiores e sequências de derrota mais longas.*

1. Introdução

1.1. Contextualização

As apostas online cresceram de forma acentuada no Brasil nos últimos anos, principalmente entre universitários. Esse crescimento trouxe também um aumento nos casos de uso problemático, muitas vezes difícil de identificar a tempo, já que o comportamento de risco se desenvolve gradualmente e nem sempre é percebido pelo próprio apostador ou por quem está ao seu redor.

1.2. Justificativa

O comportamento de risco em apostas depende da combinação de diversas variáveis simultaneamente, frequência, valor apostado, sequência de perdas, o que dificulta sua captura por meio de regras fixas definidas manualmente. Um modelo de aprendizado de máquina é capaz de aprender esses padrões diretamente dos dados, de forma mais precisa e adaptável do que abordagens baseadas em limiares arbitrários.

1.3. Motivação

Ferramentas capazes de sinalizar comportamentos de risco precocemente podem ajudar tanto o próprio usuário quanto plataformas e órgãos de saúde a agir antes que o problema se agrave.

1.4. Objetivo

Desenvolver um modelo de aprendizado de máquina supervisionado capaz de classificar o perfil de risco de um apostador (baixo, médio ou alto) a partir de características do seu comportamento de apostas.

1.5. Contribuições esperadas

O projeto pretende comparar diferentes algoritmos de classificação supervisionada, aplicar técnicas de explicabilidade, como SHAP, para identificar quais variáveis mais influenciam a classificação de risco e entregar um protótipo interativo em que o usuário informa seu padrão de apostas e recebe uma estimativa de seu perfil de risco.

2. Fundamentação Teórica e Trabalhos Relacionados

2.1. Conceitos Fundamentais

O projeto se apoia em conceitos de aprendizado de máquina supervisionado, especificamente em algoritmos de classificação, cuja tarefa é aprender, a partir de exemplos rotulados, uma função que mapeia variáveis de entrada (atributos comportamentais do apostador) a uma classe de saída (perfil de risco). Como o dataset utilizado não possui um rótulo de risco pronto, foi necessária uma etapa de engenharia de atributos, agregando dados no nível de transação (aposta individual) para o nível de apostador, e a definição de uma regra de rotulação inicial baseada em um score composto de variáveis associadas a comportamento de risco.

2.2. Trabalhos Relacionados

A literatura sobre detecção de jogo problemático por ML é ampla. Um estudo francês usou ML para prever categorias do PGSI a partir de dados de rastreamento de apostadores [Perrot et al. 2022]. Auer e Griffiths obtiveram bom desempenho (AUROC 0,74–0,75) classificando risco de apostadores australianos usando apenas dados comportamentais, sem questionários [Auer and Griffiths 2026]. Luquiens, citado pelos mesmos autores, identificou fatores de risco em jogadores de pôquer online, como padrões de depósito compulsivos [Auer and Griffiths 2024]. Já o estudo "Unmasking Risky Habits" combinou clusterização (k-means) e classificação supervisionada para rotular jogadores problemáticos [Unmasking Risky Habits 2024].

3. Metodologia e Resultados Esperados

3.1. Abordagem

O projeto segue as seguintes etapas: obtenção e limpeza dos dados, engenharia de atributos, definição de uma regra inicial de classificação de risco, análise exploratória dos perfis resultantes. Próximas etapas: treinamento e comparação de algoritmos de

classificação supervisionada, aplicação de SHAP para explicabilidade, desenvolvimento de um protótipo interativo.

3.2. Dataset

Utilizou-se o Sports Betting Profiling Dataset, disponível publicamente no Kaggle, contendo 100.000 apostas simuladas realizadas por 5.000 usuários, com as variáveis: identificador da aposta e do usuário, tipo de aposta (simples/múltipla), esporte, odds, resultado (vitória/derrota), valor apostado, valor ganho e GGR (resultado líquido da casa sobre a aposta).

Como o dataset é estruturado no nível de transação, foi necessária uma etapa de agregação por usuário, gerando as variáveis: número de apostas, valor total/médio/máximo apostado, taxa de vitória, ganho total, GGR total, odds médias, proporção de apostas múltiplas e a maior sequência de derrotas consecutivas (calculada a partir da ordem sequencial do identificador da aposta, utilizado como proxy de ordem cronológica, já que o dataset não possui timestamp).

A análise exploratória identificou uma distribuição multimodal no valor médio apostado por usuário, sugerindo a existência de subgrupos comportamentais distintos já na estrutura dos dados, um indício favorável à hipótese de que perfis de risco diferenciáveis podem ser identificados a partir dessas variáveis.

4. Resultados Parciais

4.1. Aspectos Éticos e Responsabilidade

O uso de IA para classificar pessoas em categorias de risco relacionadas à saúde exige cuidado quanto à privacidade, o dataset utilizado é público e não contém dados pessoais identificáveis, mas em uma aplicação real seria necessário anonimizar ou proteger os dados de usuários reais. Também é preciso cuidado quanto ao uso indevido do modelo, a classificação de risco não deve servir para direcionar mais anúncios de apostas a usuários de "alto risco", e sim para acionar mecanismos de proteção, como limites de aposta ou encaminhamento a apoio especializado.

4.2. Resultados Parciais Obtidos

Até o momento, foram concluídas a coleta do dataset, a limpeza e verificação de qualidade dos dados, a engenharia de atributos por usuário, e a definição e aplicação de uma regra inicial de classificação de risco. A base agregada resultante contém 5.000 apostadores, divididos em três perfis de risco de tamanho semelhante (baixo: 1.667; médio: 1.666; alto: 1.667).

A análise exploratória mostrou diferenças consistentes entre os perfis: apostadores classificados como "alto risco" apresentam, em média, maior número de apostas, maior valor médio apostado e sequências de derrota mais longas que os demais grupos (Figura 1). Além disso, é o único grupo em que o resultado financeiro líquido é favorável à casa (GGR médio positivo), enquanto o grupo de "baixo risco" apresenta, em média, resultado líquido favorável ao apostador.




Figura 1. Distribuição de valor médio apostado, número de apostas e maior sequência de derrotas por perfil de risco.

4.3. Endereço GitHub

https://github.com/LiviaCantowitz/Risco_Apostadores_IA

Referências

- Perrot, B. et al. (2022) "Development and validation of a prediction model for online gambling problems based on players' account data". Disponível em: <https://pubmed.ncbi.nlm.nih.gov/36125924/>.
- Auer, M. and Griffiths, M. D. (2026) "Predicting problem gambling among online sports and race bettors: Assessing the value of machine learning using behavioural and self-reported data", Journal of Behavioral Addictions. Disponível em: <https://www.akjournals.com/view/journals/2006/aop/article-10.1556-2006.2025.00525/article-10.1556-2006.2025.00525.xml>.
- Auer, M. and Griffiths, M. D. (2024) "Using Artificial Intelligence Algorithms to Predict Self-Reported Problem Gambling Among Online Casino Gamblers from Different Countries Using Account-Based Player Data", International Journal of Mental Health and Addiction. Disponível em: <https://link.springer.com/article/10.1007/s11469-024-01312-1>.
- Unmasking Risky Habits: Identifying and Predicting Problem Gamblers Through Machine Learning Techniques (2024), PMC. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11390795/>.
- Kaggle (2025) "Sports Betting Profiling Dataset". Disponível em: <https://www.kaggle.com/datasets/emiliencoicaud/sports-betting-profiling-dataset>.